Detección, segmentación y medición de fragmentos en fracturas pélvicas a partir de CT con una red multitarea 2.5D propia

Yáxul Santiago Cárdenas Hincapié, Nicolas Santiago Cuaran Sotelo, Juan José Orozco López, David Felipe Martínez Viracacha
Analítica de Datos, Facultad de Ingeniería, Universidad Autónoma de Occidente, Cali, Colombia · Proyecto Integrador Corte 2, 2026-2

***Resumen*—Se presenta un sistema propio que, a partir de una tomografía computarizada (CT) de pelvis fracturada, detecta el sacro y los dos coxales, separa y colorea los fragmentos de cada hueso y mide en milímetros la distancia de cada secundario al principal. Una red 2.5D con el backbone FundidoraPC extendido y CBAM alimenta tres cabezas (clasificación, detección con grid y NMS propios, y segmentación de región y borde), y una segunda etapa sin aprendizaje convierte región y borde en fragmentos. El informe se centra en las variantes probadas: primero se midió el ruido de semilla (σ = 0,0097 en Dice por fragmento) y cada candidato se juzgó contra él con validación cruzada por paciente, sin usar el test. Entre las variantes que permite el enunciado, solo lo superaron la separación por distancia, la TTA de cinco pasadas y el rescate de semillas por h-máxima. En el test de 15 pacientes: F1 0,993, mAP@[0,5:0,95] 0,864, Dice por fragmento 0,768 (meta 0,85) e IoU 0,697, no concluyente frente a 0,70. El límite está en la cabeza de borde y en la grilla de 256 px. Uso exclusivamente académico.**

***Palabras clave*—atención CBAM, detección anchor-free, fracturas pélvicas, ruido de semilla, segmentación de instancias, tomografía computarizada.**

I. Introducción

Para planear la reducción de una fractura pélvica hay que saber cuántos fragmentos hay, a qué hueso pertenece cada uno y cuánto se separó. El reto PENGWIN [1] publicó 100 tomografías con los fragmentos anotados por ortopedistas [2]. El enunciado pide un sistema propio: backbone derivado de FundidoraPC, CBAM [3] antes de la bifurcación, tres cabezas sobre un mismo backbone, grid y NMS del equipo, sin YOLO, Detectron2 ni Mask R-CNN preentrenado, y SAM solo como línea base.

Este informe recorre los datos, el modelo y, sobre todo, qué se probó y con qué prueba se descartó. Cada cifra sale de los notebooks (04_notebook) o de los archivos que leen (reports/). La validación cruzada (CV) se mide en la grilla de 256 px y el test en la grilla nativa; las tablas no las mezclan.

II. Datos y pipeline

A. Conjunto y partición

Cada caso trae el CT en unidades Hounsfield (HU) y una máscara con hasta 10 fragmentos por hueso: 1-10 sacro (SA), 11-20 coxal izquierdo (LI) y 21-30 coxal derecho (RI); 1, 11 y 21 son los principales. Los 100 casos suman 575 fragmentos, 275 de ellos secundarios, y el 88,7 % de los secundarios toca a su principal. La partición es fija y por paciente (70/15/15): entre 20 000 particiones aleatorias se eligió la de menor diferencia estandarizada máxima (SMD 0,155) en ocho variables del patrón de fractura. Para el ajuste, los 85 casos de entrenamiento y validación se dividieron en 5 folds de 17 pacientes.

B. Preprocesado

El 34 % de los volúmenes viene en orientación RAS; todos se llevan a LPS con los cosenos directores del header, sin interpolar (Fig. 1). El plano axial se recorta a un cuadrado alrededor del esqueleto calculado solo con la imagen, lo que da 1,27 mm por píxel (mediana) frente a 1,56 mm con el cuerpo entero, sin cortar hueso en ninguno de los 100 casos. La ventana L400/W1800 deja sin saturar el 99,6 % del hueso y cada corte pasa a 256 × 256; la etiqueta se remuestrea por vecino más cercano. La red recibe los cortes z−Δ, z y z+Δ como canales, con Δ = round(2 mm/dz). El objetivo de borde es la superficie entre fragmentos calculada en 3D (6-vecindad) y dilatada 2 px, de modo que también marca los contactos entre cortes vecinos.

III. Modelo

El backbone conserva las cuatro etapas de FundidoraPC

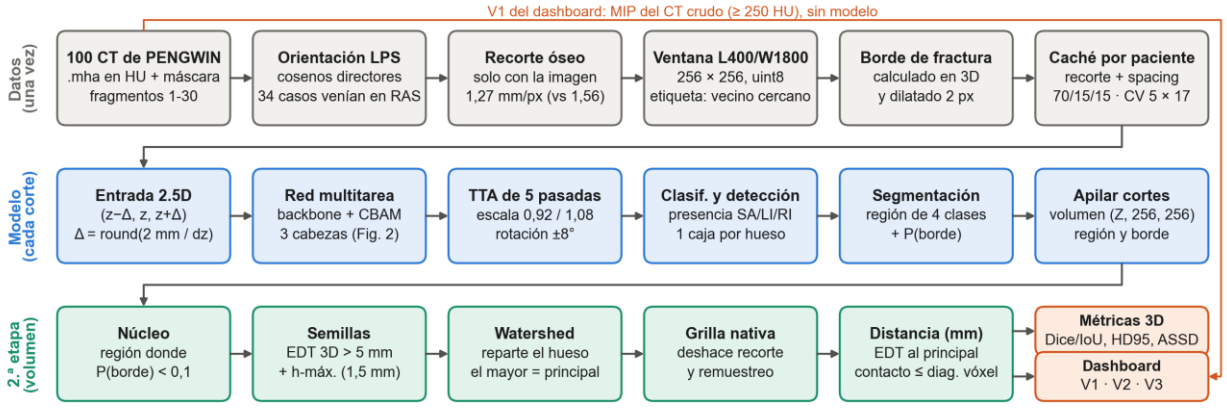


Fig. 1. Pipeline completo de los datos. Arriba, la preparación que se hace una vez por caso y queda en caché; en el centro, la inferencia corte a corte; abajo, la segunda etapa sobre el volumen apilado, sin aprendizaje, que produce los fragmentos, la distancia en mm, las métricas y los visualizadores. El visualizador 1 lee el CT crudo y no pasa por el modelo.

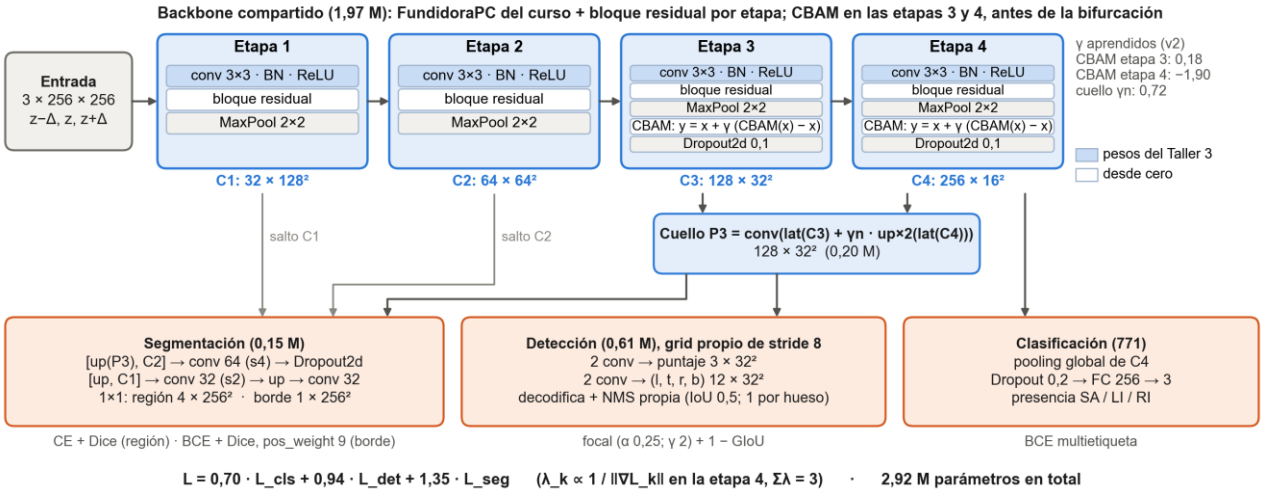


Fig. 2. Diagrama de bloques del modelo, como está en models/backbone.py y models/heads.py. En cada etapa el CBAM actúa después del MaxPool, así que las tres cabezas leen mapas que ya pasaron por él. Tensores en canales × alto × ancho; entre paréntesis, parámetros de cada bloque.

(32-64-128-256 canales) y añade un bloque residual por etapa cuya última BN arranca en cero, de modo que con los pesos cargados la red reproduce la salida original (Fig. 2). Solo las conv+BN de la FundidoraPC del Taller 3 se transfieren; lo demás parte de cero. CBAM se aplica en las etapas 3 y 4 mezclado con la identidad,

$$y = x + \gamma\,(\mathrm{CBAM}(x) - x), \tag{1}$$

con γ aprendible desde 0, que mide cuánto lo usa la red. La detección es anchor-free sobre P3 (32 × 32 celdas, stride 8): cada celda predice por hueso un puntaje y las distancias (l, t, r, b) a los lados de la caja, como FCOS [4], con pérdida focal [5] y 1 − GIoU [6]; la NMS voraz por clase deja una caja por hueso. El decodificador, con saltos a C2 y C1 como en U-Net [7], predice la región de 4 clases y el borde. La pérdida es

$$L = \lambda_{\mathrm{cls}}\,L_{\mathrm{cls}} + \lambda_{\mathrm{det}}\,L_{\mathrm{det}} + \lambda_{\mathrm{seg}}\,L_{\mathrm{seg}}. \tag{2}$$

Los λ no se copiaron de otra implementación: se calibraron por norma de gradiente, en la idea de GradNorm [8]. En 200 iteraciones con λ = 1 se midió $G_k = \|\nabla L_k\|$ sobre la etapa 4, la última capa compartida (G = 0,130; 0,097; 0,068), y se fijó $\lambda_k \propto 1/G_k$ con Σλ = 3. Se entrenó con AdamW [9] (lr $3\cdot10^{-4}$, coseno), batch 8, precisión mixta, 40 épocas, Dropout2d 0,1 y aumentación geométrica y de intensidad sin volteo, que cambiaría izquierda por derecha. Como prueba de correctitud fijada de antemano, la red memorizó 8 cortes en 500 pasos (pérdida −98,8 %, Dice 0,992, mAP@0,5 1,00).

En inferencia cada corte se predice cinco veces (identidad, escala 0,92 y 1,08, rotación ±8°) y se promedian región y borde (TTA) [10]; cajas y clasificación salen de la pasada sin transformar. En la segunda etapa, por hueso, el núcleo es la región con P(borde) < 0,1; las semillas son las zonas a más de 5 mm del borde del núcleo según la EDT 3D con el spacing del vóxel [11], más las h-máximas (h = 1,5 mm) que no caen en ninguna zona profunda; un watershed reparte el resto y el mayor fragmento es el principal. La distancia de cada secundario S a su principal P es

$$d(S) = \min_{x\in S} \mathrm{EDT}_{\neg P}(x), \quad \text{contacto} \Leftrightarrow d \le (dz^2+dy^2+dx^2)^{1/2}, \tag{3}$$

medida igual en la predicción y en la referencia.

IV. Protocolo: primero se mide el ruido

Dice e IoU por fragmento se calculan en 3D emparejando dentro de cada hueso con la asignación húngara; un real sin pareja cuenta como 0. Antes de comparar variantes se midió cuánto se mueve esa métrica solo por la semilla, y con eso se fijaron las reglas de la Tabla I. Durante el ajuste el test no se usó. Antes, dos decisiones sí lo miraron y se declaran: la época entregada de v2 (la última: mAP@[0,5:0,95] 0,864 contra 0,848 de la mejor en validación, igual Dice por fragmento) y el diagnóstico que llevó a separar por distancia, cuyo parámetro se eligió luego en validación.

Tabla I
Medición del ruido de semilla (Dice por fragmento)

Medición	Resultado	Regla que fija
Cribado: fold 0, 12 ép., semillas 42, 1337, 2024, 7	0,6925; 0,6700; 0,6770; 0,6746: σ = 0,0097	$\|\Delta\| < 2\sigma$ = 0,0195 es ruido
Confirmación: 5 folds, 20 ép., semilla 1337 vs 42	Δ −0,0007; t −0,12; desv. por fold 0,013	$\|t\| > 2{,}78$ (4 gl), ≥ 4/5 folds
Semana 11: 4 semillas + control (0,6819)	μ = 0,6792; σ = 0,0086	Dice ≥ μ + 2σ = 0,6964
Afinado por etapas (regla previa)	—	Δ ≥ 0,026, $t > 2{,}776$, ≥ 4/5

V. Qué se probó y por qué se descartó

A. Dónde está el error

Separar quitando de la región los píxeles de borde recuperaba el 12,8 % de los secundarios en test. Al reemplazar por la referencia, por separado, la región y el borde predichos (Tabla II), el borde real sube el Dice por fragmento de 0,745 a 0,902 y la región real solo a 0,770. La cabeza de borde marca el 16 % de la superficie de fractura (umbral 0,2) y bajar el umbral casi no sube ese recall. De ahí la separación por distancia: una grieta o un puente delgado nunca tiene vóxeles a más de 5 mm del borde del núcleo, así que separa aunque la red rellene la grieta. En validación 5 mm fue la mejor profundidad (67,3 % de secundarios; 4 mm, 61,3 %; 6 mm, 59,5 %) y la CV lo confirmó: +0,247 frente a separar solo por el borde.

TABLA IV
CONFIRMACIÓN EMPAREJADA POR FOLD (CV, 5 FOLDS DE 17 PACIENTES): Δ Y T CONTRA LA REFERENCIA DE CADA BLOQUE

Variante	Dice frag.	Δ Dice	t	Folds	Δ principal	Decisión
Referencia: v2 de 20 épocas, semilla 42, sin TTA, separación por distancia (Dice 0,7453; IoU 0,6828). (*) Contra la referencia de semilla 1337 (0,7446)						
Misma configuración, semilla 1337 (control)	0,7446	−0,0007	−0,12	3/5	−0,023	mide el ruido
Repetir ×3 cortes con secundarios	0,7540	+0,0087	0,94	3/5	+0,004	descartado: ruido
Sin transfer learning · semilla 42 / 1337 (*)	0,7594 / 0,7522	+0,0141 / +0,0076	1,04 / 0,60	3/5 · 3/5	+0,004 / +0,027	sin efecto (10 pares: t 1,23)
Sin CBAM	0,7365	−0,0088	−0,92	1/5	−0,001	sin efecto; queda (enunciado)
Borde como núcleo/borde de 3 clases	0,6729	−0,0724	−3,13	1/5	+0,005	descartado (con distancia: +0,0008)
Borde como regresión de la distancia a la fractura	0,5039	−0,2414	−10,88	0/5	−0,006	descartado (con distancia: −0,0155)
Semillas solo por h-máxima	0,7600	+0,0147	1,01	4/5	−0,043	descartado: parte el principal
Distancia + rescate h-máx. (F2C2), h 1,0 · 42 / 1337 (*)	0,7723 / 0,7635	+0,0270 / +0,0199	2,27 / 2,35	5/5 · 4/5	−0,009 / −0,011	no: réplica pasa el límite 0,010
F2C2, h 1,5 · 42 / 1337 (*)	0,7744 / 0,7717	+0,0291 / +0,0281	2,19 / 3,24	4/5 · 5/5	−0,010 / −0,010	se retoma con TTA
Ensamble de 2 semillas / de 6 modelos	0,7570 / 0,7788	+0,0117 / +0,0335	1,75 / 4,19	3/5 · 5/5	+0,002 / +0,009	descartado: varios backbones
Ensamble de 2 / de 6 + F2C2	0,7849 / 0,7975	+0,0396 / +0,0522	3,77 / 3,28	5/5 · 5/5	−0,009 / −0,005	descartado: varios backbones
TTA de 5 pasadas · semilla 42 / 1337 (*)	0,7638 / 0,7533	+0,0185 / +0,0087	2,35 / 0,84	4/5 · 3/5	+0,003 / +0,026	sola no basta
TTA de 5 pasadas + F2C2 h 1,5 · 42 / 1337 (*)	**0,7922 / 0,7812**	**+0,0469 / +0,0366**	**4,13 / 3,66**	**5/5 · 4/5**	**−0,006 / +0,016**	**adoptado (tuned.yaml)**
TTA de 9 pasadas + F2C2	0,7802	+0,0349	2,29	4/5	−0,009	descartado: −0,012 vs TTA 5
Referencia: configuración final en CV, TTA 5 + F2C2 (Dice 0,792; IoU 0,717)						
Afinar solo la segmentación 8 épocas, resto congelado	0,777	−0,015	−5,21	0/5	−0,003	descartado: congelar empeora
Control: entrenar todo el modelo las mismas 8 épocas	0,790	−0,002	−0,35	3/5	0,000	sin cambio
EMA 0,999 contra el mismo modelo sin EMA	—	0,000	0,02	2/5	0,000	descartada: sin efecto
Ajuste fino: min_fragment, seed_min; profundidad 5,5 mm	≤ 0,7922; 0,7955	≤ 0; +0,009	—	—	— / baja	sin efecto; ΔIoU +0,003 mixto
Referencia: la misma configuración sin cierre, contra la etiqueta nativa (85 casos, 2 semillas)						
Cierre morfológico del hueco, radio 1,5-3 mm	0,7727-0,7858	−0,0002 a −0,0023	—	0/5	—	descartado: túneles −30-50 %
Cierre solo en coxales, radio 5-7 mm	0,7716-0,7839	−0,0021 a −0,0035	—	0/5	—	descartado: el hueco sigue

TABLA II
DIAGNÓSTICO CON SALIDAS REALES (CV, 5 FOLDS, GRILLA DE 256 PX)

Separación	Región	Borde	Dice frag.	IoU frag.	Secund. rec.
solo borde	predicha	predicho	0,498	0,460	4,9 %
distancia	predicha	predicho	0,745	0,683	59,5 %
distancia	real	predicho	0,770	0,729	59,6 %
distancia	predicha	real	0,902	0,856	90,6 %
distancia	real	real	0,989	0,984	99,1 %

B. Cribado de hiperparámetros

Los cambios de entrenamiento se cribaron en el fold 0 a 12 épocas, cada uno con su mejor posproceso, igual que las semillas (Tabla III). Nueve de diez quedan dentro de ±2σ; frenar el backbone (lr × 0,3) empeora 4,3σ, y el mejor (+1,1σ) no se sostuvo en la confirmación. El dropout de 0,25 a 0,40 no muestra tendencia (0,674; 0,662; 0,686; 0,687); subirlo de 0 a 0,40 cierra la brecha de la pérdida de borde (0,22 a 0,08) porque empeora el entrenamiento, no porque mejore la validación (0,47-0,49). En la semana 11 los tres remedios que faltaban contra ese sobreajuste no llegaron al umbral; U-Net++ [12] quedó a 0,003, con un borde más preciso (0,43 contra 0,37) e igual recall (0,16).

TABLA III
CRIBADO EN EL FOLD 0 (12 ÉPOCAS); REFERENCIA: SEMILLA 42, 0,6925

Cambio	Dice frag.	Δ	Δ/σ	Decisión
×3 cortes con secundarios	0,7031	+0,0106	+1,09	confirmar
lr 10^{-3} (base $3{\cdot}10^{-4}$)	0,6963	+0,0038	+0,39	ruido
Dilatación del borde 1 / 3	0,6939 / 0,6875	+0,0014 / −0,0049	+0,14 / −0,51	ruido
Peso del borde 4 / 16	0,6908 / 0,6835	−0,0017 / −0,0090	−0,17 / −0,92	ruido
Dropout 0,2 / sin dropout	0,6905 / 0,6891	−0,0020 / −0,0034	−0,21 / −0,35	ruido
Aumentación fuerte	0,6805	−0,0120	−1,23	ruido
Backbone con lr × 0,3	0,6503	−0,0421	−4,32	peor
Semana 11; regla: Dice ≥ μ + 2σ = 0,6964 (Tabla I)				
L2 × 100 (wd 10^{-2})	0,6829	−0,0096	z 0,43	no pasa
Decodificador 32 canales	0,6899	−0,0026	z 1,25	no pasa
U-Net++ con C0	0,6934	+0,0009	z 1,66	no pasa

C. Confirmación en 5 folds

En la confirmación (Tabla IV) ningún cambio de entrenamiento ni de arquitectura supera el ruido. Sin CBAM o sin transfer learning (TL) el Dice no cambia; el efecto del TL depende del paciente, no de la semilla (el fold 1 gana sin TL con las dos semillas y los folds 3-4 pierden con las dos). Las dos representaciones nuevas del borde empeoran con su método, pero esos modelos con la separación por distancia igualan a la referencia: falló la representación, no el aprendizaje. Afinar solo la segmentación con el resto congelado, sugerido en el avance del 9 de octubre, empeora (t = −5,2): con el backbone fijo la pérdida de borde baja en entrenamiento (0,223 a 0,208) y sube en validación (0,424 a 0,429). Lo que sí superó el ruido fue no perder semillas y promediar: TTA 5 + F2C2 da +0,047 (t = 4,1, 5/5) y +0,037 con la otra semilla. F2C2 solo no se había adoptado porque una réplica pasó por 0,0012 el límite fijado para el principal; su adopción junto con TTA se declara posterior a ver los datos. El ensamble de seis modelos (0,798) se descartó porque el enunciado pide un mismo backbone.

VI. RESULTADOS EN TEST

La Tabla V compara tres versiones del modelo en el mismo test; TTA no cambia clasificación ni detección. En la prueba de estrés, con todos los cortes, el mAP@0,5 sigue en 0,980, baja a 0,972 si cuentan las cajas menores de 4 px y cae a 0,234 con las cajas de otro paciente: la cifra no viene de la forma de evaluar. Con 15 pacientes, el bootstrap por paciente (5000 réplicas) deja el 0,85 de Dice fuera del intervalo; el del IoU contiene el 0,70 y el 48 % de las réplicas lo supera, así que no se puede afirmar que se cumpla ni que no. En la misma grilla nativa la configuración final da 0,786 en CV y 0,768 en test, caída compatible con elegir la mejor entre muchas variantes.

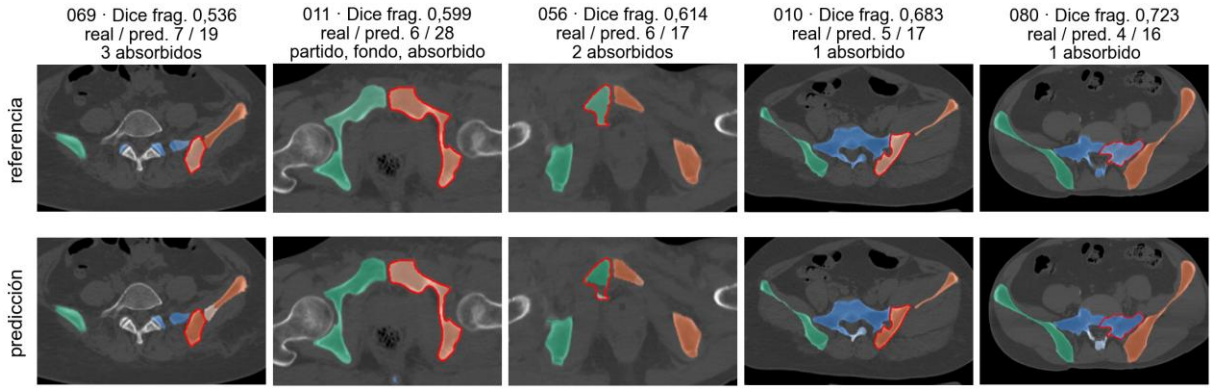


Fig. 3. Los cinco peores casos de test, un corte por paciente. Arriba, referencia; abajo, predicción; en rojo, el contorno real de un secundario perdido. Sobre cada columna, el Dice por fragmento del caso, los fragmentos reales contra los predichos y qué pasó con los secundarios perdidos.

TABLA V
TEST (15 PACIENTES, GRILLA NATIVA) POR VERSIÓN DEL MODELO

Métrica	Meta	Base, solo borde	v2 + distancia	Final	IC95 final
F1 clasificación	≥ 0,85	0,993	0,993	0,993	—
AUC clasificación	≥ 0,85	0,999	0,999	0,999	—
IoU de caja	≥ 0,65	0,911	0,919	0,919	—
mAP@0,5	≥ 0,65	0,977	0,980	0,980	—
mAP@[0,5:0,95]	≥ 0,40	0,841	0,864	0,864	—
Dice por fragmento	**≥ 0,85**	**0,545**	**0,725**	**0,768**	**[0,702; 0,827]**
IoU por fragmento	**≥ 0,70**	**0,505**	**0,671**	**0,697**	**[0,636; 0,753]**
Dice principal (45)	—	0,921	0,930	0,924	
Dice secundario (39)	—	0,111	0,489	0,588	
Secundarios < 5 cm³ (7)	—	0,222	0,000	0,526	
Secundarios recuperados	—	12,8 %	51,3 %	56,4 %	
HD95 / ASSD (mm)	opc.	—	—	11,7 / 3,3	
Distancia al principal: |predicha − real| en los secundarios recuperados (mm)					
Media / mediana	—	1,06 / 0,69	2,20 / 0,00	1,96 / 0,00	
En contacto / separados	—	1,61 / 0,69	2,40 / 1,08	2,32 / 0,75	

Final = v2 + TTA de 5 pasadas + F2C2. Entre paréntesis, fragmentos reales. Distancia medida en 5, 20 y 22 secundarios.

A. Ablación, línea base SAM y uso del CBAM

TABLA VI
SEGMENTACIÓN POR REGIÓN EN TEST (MISMA MÉTRICA PARA TODOS)

Modelo	Dice región	Dice SA	IoU región	mAP@[.5:.95]
Base (CBAM + TL), semana 9	0,968	0,954	0,938	0,841
Sin CBAM	0,970	0,960	0,942	0,845
Sin transfer learning	0,971	0,961	0,944	0,840
v2, época 39 (entregado, sin TTA)	0,971	0,961	0,944	0,864
SAM ViT-B + caja predicha (base)	0,908	0,863	0,832	—
SAM ViT-B + caja real	0,908	0,866	0,832	—

En test, con una semilla, los modelos con y sin CBAM y con y sin TL empatan (Tabla VI), igual que en CV. El γ lo confirma: el del CBAM de la etapa 3 queda en 0,18 y apagarlo no cambia nada (Δ mAP −0,002); el de la etapa 4 llega a −1,90, es decir, la red invierte la atención ($y = 2{,}9x - 1{,}9\cdot\mathrm{CBAM}(x)$), y al repetir el entrenamiento vuelve a −1,83 mientras el de la etapa 3 termina en 0,41. Con Grad-CAM [13] sobre C4, solo el 3-6 % de la activación cae sobre el hueso clasificado. CBAM se mantiene porque el enunciado lo exige. El TL acelera el arranque (mAP@[0,5:0,95] de validación 0,730 contra 0,679 desde cero en la época 2) y luego se iguala. SAM [14] con la caja predicha queda 6 puntos de Dice por debajo y 9 en el sacro, y rinde igual con la caja real: lo limita el dominio, no el detector.

B. Matriz de confusión

En la clasificación por corte (Tabla VII) el sacro es el que más falla, casi siempre en los extremos del hueso, donde aparece o desaparece en pocos píxeles. Por píxel, la confusión entre huesos es del 0,06 % y la lateralidad es correcta, que era el riesgo de los 34 volúmenes en RAS; el error está contra el fondo (recall por hueso 0,984-0,987, sobre todo en ramas finas).

TABLA VII
CONFUSIÓN DE LA CLASIFICACIÓN POR CORTE (TEST, 4840 CORTES)

Hueso	VP	FN	FP	VN	Precisión	Recall	F1
Sacro (SA)	2440	45	44	2311	0,982	0,982	0,982
Coxal izq. (LI)	3589	8	4	1239	0,999	0,998	0,998
Coxal der. (RI)	3566	5	3	1266	0,999	0,999	0,999

C. Los cinco peores casos

En los cinco pacientes con menor Dice por fragmento (Fig. 3) se perdieron 10 secundarios y se midió dónde quedaron sus vóxeles. Los 10 tocan a su principal en la referencia: 8 quedaron absorbidos por él (82-98 % de sus vóxeles), uno de 95 cm³ se cortó por otro sitio (IoU 0,48) y uno de 3,8 cm³ salió como fondo. Los principales salen bien (Dice 0,88-0,93) y se predicen de 16 a 28 fragmentos donde hay de 4 a 7. Hipótesis: sin un borde continuo sobre la superficie de fractura el núcleo no se corta y la semilla del principal invade al secundario, la misma causa que señala la Tabla II.

D. Distancia de separación y latencia

De los 39 secundarios reales, 22 (56 %) se recuperan y tienen distancia comparable con la referencia (Tabla V): la mediana del error es 0,00 mm, y 17 de los 22 están en contacto. El error medio de 1,96 mm lo domina el caso 009 (39,4 mm), en el que el principal del coxal derecho quedó mal segmentado (Dice 0,72) y el secundario se midió contra otro pedazo: así pasa un error de segmentación a la medida. Los otros 17 secundarios no tienen distancia que medir.

Latencia por corte (modelo, decodificación y NMS) en una laptop con RTX 3060 e Intel i7-11800H: sin TTA, 7,7 ms en GPU y 66 ms en CPU; con TTA, 33,8 ms y 309 ms (7,4 s por volumen de 401 cortes en GPU). A batch 1 la precisión mixta no acelera (10,3 ms).

VII. Dashboard y despliegue

El dashboard es una aplicación FastAPI de una página con los tres visualizadores (Fig. 4): la MIP del CT crudo con umbral de 250 HU, sin modelo; el recorrido corte a corte con cajas, máscaras y la distancia sobre cada secundario; y la malla por fragmento con marching cubes y Plotly Mesh3d, con la distancia junto a cada etiqueta. Recibe volúmenes .mha, .nii o .nrrd por trozos (de 39 a 434 MB) o cortes sueltos PNG, JPEG o DICOM. Corre en una NVIDIA DGX Spark (GPU GB10) y se publica con HTTPS en el VPS del equipo por un túnel SSH inverso: el túnel de Cloudflare no fue posible porque la red de la GPU bloquea su puerto de salida (7844). El caso 019 (184 MB) se procesó en 16 s.

VIII. Limitaciones

Al revisar los visualizadores apareció un hueco en el ala ilíaca de la malla 3D (Fig. 4c) que no es fractura ni sobreajuste sino efecto del remuestreo: 102 de los 300 principales ganan túneles al pasar a 256 px. Casi no afecta al Dice (en el 075, menos de 0,1 cm³ de 305 cm³), pero se ve en la malla, y cerrarlo en el posproceso baja las métricas sin quitarlo (Tabla IV). La Tabla VIII reúne las limitaciones.

Tabla VIII
Limitaciones conocidas

Limitación	Evidencia	Consecuencia
Contacto entre fragmentos	recall del borde 0,16; 10/10 perdidos en contacto	Dice frag. < 0,85; 44 % sin distancia
Grilla de 256 px	102/300 principales ganan túneles; ala de 0,85-1,7 mm	huecos en la malla 3D
Sobreajuste del borde	BCE val. 0,018 → 0,034; nueve remedios sin efecto	hipótesis: etiqueta a 256 px
Test de 15 pacientes	IC95 del IoU [0,636; 0,753]	meta de IoU no concluyente
Fragmentos de más	16-28 predichos contra 4-7 reales	se ven en la malla
Aumentación fija	con persistent_workers la época no llega al DataLoader (ed3e807)	misma transformación por corte; efecto no medido
Fugas leves	época de v2 y diagnóstico inicial del borde vistos en test; EDA con 100 casos	declaradas
Un solo conjunto	100 CT alineados; oblicuos solo sintéticos	sin validación externa

IX. Conclusiones

El sistema cumple los requisitos funcionales y de arquitectura y cinco de las siete metas; el Dice por fragmento queda en 0,768 frente a 0,85 y el IoU en 0,697, no concluyente. Medir el ruido antes de comparar mostró que casi todas las mejoras aparentes eran ruido de semilla; lo que lo superó fue cambiar cómo se separan los fragmentos y promediar predicciones del mismo modelo. El borde que no se detecta y el hueco del ala ilíaca son el mismo límite: grietas y láminas de uno o dos milímetros quedan por debajo de un píxel de 1,3 mm. El paso siguiente sería entrenar con etiquetas a mayor resolución o con una segunda pasada a resolución nativa sobre cada hueso detectado.

Referencias

[1] PENGWIN Challenge, "Pelvic bone fragments with injuries segmentation challenge," MICCAI, 2024. [Online]. Disponible: https://pengwin.grand-challenge.org

[2] PENGWIN Challenge, "PENGWIN CT training data," Zenodo, 2024. [Online]. Disponible: https://zenodo.org

[3] S. Woo, J. Park, J.-Y. Lee y I. S. Kweon, "CBAM: Convolutional block attention module," in *Proc. ECCV*, Múnich, Alemania, 2018, pp. 3-19.

[4] Z. Tian, C. Shen, H. Chen y T. He, "FCOS: Fully convolutional one-stage object detection," in *Proc. ICCV*, Seúl, Corea, 2019, pp. 9627-9636.

[5] T.-Y. Lin, P. Goyal, R. Girshick, K. He y P. Dollár, "Focal loss for dense object detection," in *Proc. ICCV*, Venecia, Italia, 2017, pp. 2980-2988.

[6] H. Rezatofighi et al., "Generalized intersection over union: A metric and a loss for bounding box regression," in *Proc. CVPR*, Long Beach, EE. UU., 2019, pp. 658-666.

[7] O. Ronneberger, P. Fischer y T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Proc. MICCAI*, Múnich, Alemania, 2015, pp. 234-241.

[8] Z. Chen, V. Badrinarayanan, C.-Y. Lee y A. Rabinovich, "GradNorm: Gradient normalization for adaptive loss balancing in deep multitask networks," in *Proc. ICML*, Estocolmo, Suecia, 2018, pp. 794-803.

[9] I. Loshchilov y F. Hutter, "Decoupled weight decay regularization," in *Proc. ICLR*, Nueva Orleans, EE. UU., 2019.

[10] G. Wang, W. Li, M. Aertsen, J. Deprest, S. Ourselin y T. Vercauteren, "Aleatoric uncertainty estimation with test-time augmentation for medical image segmentation with convolutional neural networks," *Neurocomputing*, vol. 338, pp. 34-45, 2019.

[11] C. R. Maurer, R. Qi y V. Raghavan, "A linear time algorithm for computing exact Euclidean distance transforms of binary images in arbitrary dimensions," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 25, no. 2, pp. 265-270, 2003.

[12] Z. Zhou, M. M. Rahman Siddiquee, N. Tajbakhsh y J. Liang, "UNet++: A nested U-Net architecture for medical image segmentation," in *Proc. DLMIA (MICCAI Workshops)*, Granada, España, 2018, pp. 3-11.

[13] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh y D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. ICCV*, Venecia, Italia, 2017, pp. 618-626.

[14] A. Kirillov et al., "Segment anything," in *Proc. ICCV*, París, Francia, 2023, pp. 4015-4026.

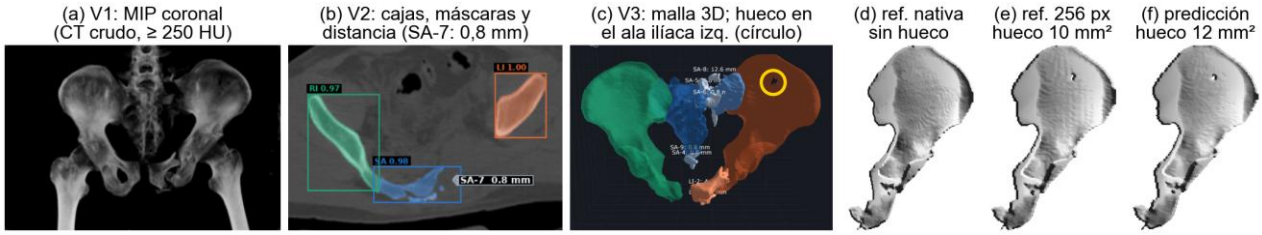


Fig. 4. (a)-(c) Los tres visualizadores del dashboard en el caso 075 de test. En (c) la malla del coxal izquierdo muestra un hueco en el ala ilíaca que no es una fractura. (d)-(f) Origen del hueco: el ala mide 0,85-1,7 mm y la referencia nativa no lo tiene; al pasarla a 256 px (1,36 mm por píxel, vecino más cercano) el puente se pierde, y el modelo, entrenado con esas etiquetas, lo reproduce.