

UNIVERSIDAD AUTÓNOMA DE OCCIDENTE

PROYECTO INTEGRADOR CORTE 2

Sistema de detección, segmentación y clasificación de fracturas pélvicas a partir de tomografía
computarizada
(dataset PENGWIN)

Grupos de 4–5 estudiantes

Semestre 2026-2

1. Contexto y propósito del proyecto

Las fracturas pélvicas de alta energía se encuentran entre las lesiones ortopédicas de mayor complejidad, debido a sus elevadas tasas de discapacidad y mortalidad. En el contexto de la planeación quirúrgica de su reducción, es necesario identificar los fragmentos óseos presentes, determinar a qué región anatómica pertenecen y estimar su separación con respecto a la posición del hueso de origen. Actualmente, buena parte de este proceso depende de la interpretación experta de imágenes de tomografía computarizada (CT).

En este proyecto se trabajará con el dataset internacional PENGWIN (Pelvic Bone Fragments with Injuries Segmentation Challenge, MICCAI 2024–2026), utilizado como fuente de datos real con anotaciones de fragmentos validadas por expertos ortopedistas. El propósito es que cada equipo diseñe e implemente un sistema propio que integre detección, segmentación, clasificación y medición, evitando limitarse al uso directo de arquitecturas de alto nivel previamente entrenadas.

El sistema desarrollado deberá ser capaz de:

- Detectar cada región ósea pélvica presente en un corte de CT.
- Segmentar los fragmentos individuales dentro de cada región y clasificarlos según el hueso al que pertenecen, utilizando una codificación por color.
- Medir, en milímetros, la distancia de separación de cada fragmento conminuto respecto al fragmento principal del hueso al que pertenece.
- Integrar los resultados en un dashboard interactivo con tres visualizadores y un demo desplegado en vivo.

Alcance académico y uso responsable. El sistema desarrollado tiene exclusivamente fines académicos. No constituye un dispositivo médico, no ha sido validado clínicamente y no debe presentarse ni utilizarse como herramienta para apoyar decisiones quirúrgicas reales. Esta advertencia deberá aparecer de manera visible tanto en el dashboard como en el model card de cada equipo.

2. Dataset: [PENGWIN](https://pengwin.grand-challenge.org)

Fuente de datos: pengwin.grand-challenge.org.

El dataset contiene cortes de CT de pacientes con fractura pélvica, acompañados de máscaras de fragmentos anotadas y validadas por expertos ortopedistas. Por esta razón, los equipos no deberán generar manualmente nuevas etiquetas para cumplir con los requisitos del proyecto.

2.1 Taxonomía anatómica

La taxonomía deberá utilizarse exactamente como se encuentra definida en el dataset. Cada hemipelvis se consolida como una única región anatómica por lateralidad; por tanto, no se deberán subdividir de manera independiente el ilion, el isquion y el pubis. Una taxonomía más detallada no tendría un ground truth verificable y no será aceptada como parte del entregable.

Categoría anatómica	Lateralidad	Descripción
Sacro (SA)	No aplica (línea media)	Hueso único, sin lateralidad.
Hueso coxal izquierdo	Izquierda	Incluye ilion, isquion y pubis fusionados.
Hueso coxal derecho	Derecha	Incluye ilion, isquion y pubis fusionados.

Cada región anatómica puede contener hasta 10 fragmentos etiquetados individualmente cuando existe una fractura. Cuando el hueso no presenta fractura, se representa como un único fragmento.

2.2 Acceso y manejo de los datos

Los conjuntos de entrenamiento están disponibles en Zenodo. Antes de iniciar la semana 1, cada equipo deberá verificar el proceso de registro y aceptación de términos. Si se requiere una aprobación con tiempo de espera, esta deberá resolverse antes de la publicación del proyecto.

El espaciado físico del vóxel (mm/vóxel) deberá obtenerse del header del archivo NIfTI y utilizarse en todas las medidas de distancia. En ningún caso deberá reportarse una distancia expresada en píxeles como si correspondiera a una medida clínica.

3. Requisitos funcionales obligatorios

El proyecto se estructura en cuatro pilares funcionales que deberán estar implementados y operativos en todos los equipos. Los diferentes niveles de desempeño podrán reflejarse en la robustez, precisión y calidad de la solución, pero ninguno de estos cuatro componentes podrá omitirse.

3.1 Detección

El sistema deberá localizar mediante bounding boxes cada región anatómica presente en el corte. Para ello se utilizará una cabeza de detección propia. La supresión de no máximos (NMS) deberá ser implementada por el equipo.

3.2 Segmentación y clasificación de fragmentos

El sistema deberá generar una máscara de instancia para cada fragmento óseo y asignar un color de acuerdo con la región anatómica de pertenencia: sacro, coxal izquierdo o coxal derecho. La arquitectura deberá combinar una salida semántica, correspondiente a la categoría anatómica, con una salida de instancia para identificar cada fragmento individual. Se seguirá una lógica de dos etapas; primero se identifican las regiones anatómicas generales y posteriormente los fragmentos contenidos dentro de cada región, de acuerdo con la lógica descrita en la literatura del challenge.

3.3 Medición de la distancia de separación

Para cada fragmento conminuto (segmento ósea que salió de la fractura del macrosegmento óseo) se deberá calcular la distancia mínima borde a borde, expresada en milímetros, respecto al fragmento principal del mismo hueso. La medición deberá utilizar el espaciado físico del header del NIfTI y una transformada de distancia mediante `scipy.ndimage.distance_transform_edt` sobre las máscaras segmentadas.

Como parte del análisis del desempeño, también deberá calcularse la misma distancia sobre la máscara de referencia (ground truth) correspondiente al mismo caso. Esta comparación permitirá identificar cuánto error puede transferirse desde la calidad de la segmentación hacia la medida de separación.

3.4 Dashboard y visualizadores obligatorios

Visualizador	Contenido obligatorio	Método
1. Volumen crudo (raw)	Reconstrucción 3D inicial del volumen original mediante una vista de proyección de máxima intensidad (MIP), mostrando únicamente el hueso.	Umbral de intensidad en unidades Hounsfield sobre el volumen sin procesar. No interviene el modelo; corresponde a un paso de preprocesamiento clásico.
2. Inferencia corte por corte	Detección, segmentación y clasificación del modelo, con un control que permita recorrer los cortes del volumen mediante un slider.	Overlay 2D de bounding boxes y máscaras coloreadas sobre cada corte, generado por el pipeline entrenado.
3. Reconstrucción 3D final	Reconstrucción tridimensional del hueso con los fragmentos coloreados según el macro-hueso al que fueron asignados, incluyendo la distancia de separación visible junto a la etiqueta de cada fragmento.	Apilamiento de máscaras predichas + marching cubes (skimage) + malla interactiva (Plotly Mesh3d).

La distancia de separación de cada fragmento deberá ser visible directamente en los visualizadores 2 y 3. No será suficiente presentarla únicamente en una tabla, dado que constituye una parte esencial del resultado que debe interpretarse de manera rápida.

4. Arquitectura técnica requerida

4.1 Diseño obligatorio

Backbone compartido: se deberá utilizar una extensión propia del backbone del curso (FundidoraPC) o una arquitectura equivalente diseñada por el equipo. Se permite transfer learning únicamente en el backbone (entrenamiento de la fundidora de pc en dataset previamente usados, esto si almacenaron los pesos), utilizando pesos preentrenados en ImageNet u otro dataset natural; las cabezas **deberán entrenarse desde cero**.

Bloque de atención CBAM: deberá incorporarse atención de canal y espacial en el backbone, antes de la bifurcación hacia las tres cabezas.

Tres cabezas sobre un mismo backbone: clasificación de la categoría anatómica, detección de bounding boxes por región mediante grid propio y NMS propio, y segmentación de instancia de los fragmentos con coloración según pertenencia anatómica.

Función de pérdida compuesta multitarea: los pesos (λ) de cada término deberán ser calibrados y justificados explícitamente en el informe. No se aceptarán valores copiados de otras implementaciones sin una argumentación relacionada con el proyecto.

Restricciones de implementación.

Está explícitamente prohibido utilizar YOLO, en cualquiera de sus versiones, Detectron2, Mask R-CNN preentrenado o cualquier framework de detección o segmentación de alto nivel como arquitectura entregada. Las publicaciones asociadas a estas herramientas sí pueden consultarse para comprender principios como grid, NMS o anchor-free, siempre que la implementación final sea propia y esta decisión quede declarada en el informe.

4.2 Uso de SAM

SAM deberá utilizarse exclusivamente como referencia de comparación (baseline zero-shot). No podrá formar parte del pipeline final ni utilizarse para generar las etiquetas, dado que el dataset ya proporciona máscaras validadas por expertos. Cada equipo deberá ejecutar SAM utilizando como prompt el bounding box predicho sobre el conjunto de prueba y reportar Dice e IoU frente al modelo propio. La comparación deberá utilizarse como evidencia experimental para analizar el comportamiento de un modelo generalista fuera de dominio frente a un modelo entrenado específicamente para la tarea.

4.3 Restricciones de cómputo

- Se recomienda trabajar con una resolución de 224–256 píxeles por corte y un batch de 8–16.
- Deberá utilizarse precisión mixta mediante torch.cuda.amp.
- El pipeline de inferencia deberá poder ejecutarse tanto en GPU como en CPU.
- Cada equipo deberá medir y reportar la latencia por imagen en ambos escenarios.

5. Métricas y objetivos de desempeño

El challenge PENGWIN utiliza métricas como IoU fragmentwise, HD95 y ASSD, en lugar de depender exclusivamente de métricas de detección como mAP estilo COCO. Sus mejores resultados provienen de arquitecturas 3D especializadas y de procesos de ajuste considerablemente más extensos. Por ello, los objetivos establecidos para este proyecto corresponden a un reto académico de cuatro semanas con una arquitectura propia 2D (corte a corte, manteniendo el fundamento del análisis 3D sobre el volumen CT) y se sitúan deliberadamente por debajo del techo de desempeño del challenge.

Tarea	Métrica	Objetivo sugerido
Clasificación (categoría anatómica)	F1-score	≥ 0.85
Clasificación (categoría anatómica)	AUC	≥ 0.85
Detección (bbox por región)	IoU promedio	≥ 0.65
Detección (bbox por región)	mAP@0.50	≥ 0.65
Detección (bbox por región)	mAP@[0.50:0.95]	≥ 0.40
Segmentación de fragmento	Dice	≥ 0.85
Segmentación de fragmento	IoU	≥ 0.70

Extensión opcional: Los equipos que deseen profundizar podrán reportar HD95 (distancia de Hausdorff al percentil 95) y ASSD (distancia de superficie simétrica promedio) por fragmento, replicando las métricas utilizadas en el challenge. Estas métricas son valiosas para el análisis, pero no hacen parte del requisito mínimo. (pueden otorgar puntos extras)

6. Cronograma de trabajo para evaluación de avances

Semana	Entregable verificable
8	Dataset curado con splits fijos; pipeline de carga NIfTI y ventaneo HU funcionando; análisis exploratorio (EDA) de fragmentos por caso; visualizador 1 (MIP raw) implementado y operativo.
9	Backbone, CBAM y cabeza de detección implementados; overfit intencional sobre un batch pequeño como prueba de correctitud; primeras predicciones de bounding boxes visualmente razonables.
10	Pipeline completo: detección → NMS → segmentación de instancia → clasificación por pertenencia. Entrenamiento completo, medición de distancia de separación, comparación contra SAM y cálculo de las métricas definidas en la sección 5.
11 (Entrega)	Visualizadores 2 y 3 terminados; dashboard integrado; despliegue mediante túnel de Cloudflare; medición de latencia en CPU/GPU; model card, pitch y repositorio final con pesos y pipeline reproducible.

7. Entregables finales

- Repositorio de GitHub con historial de commits y Pull Requests por integrante. La rama main deberá estar protegida y los merges deberán realizarse después de una revisión por pares.
- Pesos entrenados de cada modelo (checkpoints .pth) y pipeline completamente reproducible, incluyendo requirements.txt o environment.yml, semillas fijas y README con los comandos exactos de reproducción.
- Dashboard desplegado en vivo mediante un túnel de Cloudflare, accesible desde un navegador en computador (GPU/CPU) y teléfono celular.
- Medición del desempeño en GPU y CPU, reportando explícitamente la latencia por imagen.
- Model card para cada modelo entrenado, con arquitectura, datos de entrenamiento, métricas obtenidas, alcances, limitaciones conocidas, incluido el caso de fragmentos que entran en contacto en la superficie de fractura y pueden fusionarse por errores de segmentación, y la advertencia de uso no clínico.

- Archivo IA_USAGE.md que registre el modelo de IA generativa utilizado, el prompt exacto, la parte del código o decisión que se obtuvo mediante IA y las modificaciones realizadas manualmente por el equipo.
- Informe técnico corto con estructura de mini-paper, que incluya la motivación de las decisiones arquitectónicas, un estudio de ablación (con/sin CBAM y con/sin transfer learning en el backbone), matriz de confusión de clasificación, galería de los cinco peores casos de detección/segmentación con hipótesis sobre sus causas y comparación de la distancia de separación entre predicción y ground truth.
- IA_USAGE.md con los prompts y respuestas o sugerencias dadas por modelos de IA usados como apoyo, y su análisis o comparación respecto a lo que les indico y el resultado alcanzado (análisis crítico de errores, aciertos y limitaciones encontradas)
- Pitch final de 25 minutos (15 min presentación y 10 min demostración y preguntas) que presente el problema, la arquitectura, los resultados, las limitaciones y una demostración en vivo. El equipo deberá disponer de un video pregrabado como respaldo ante una eventual falla de conexión del túnel durante la sustentación (solo una persona seleccionada por mí, Carlos ferro, realizará la sustanciación y se hará cargo de la nota del curso).